

# Classificação de Estrelas e Galáxias através de Redes Neurais Artificiais

Moésio Wenceslau da Silva Filho<sup>1</sup>

<sup>1</sup>Departamento de Computação – Universidade Federal Rural de Pernambuco (UFRPE)  
Recife – PE – Brazil

moesio.wenceslau@ufrpe.br

**Resumo.** *Esse artigo apresenta os resultados da implementação do artigo [Premanand et al. 2023], realizando a mesma análise dos autores e incorporando outras arquiteturas de Redes Neurais Artificiais nos experimentos. Em particular, foram treinados diferentes classificadores baseados em Redes Neurais Artificiais para identificar a classe de um dado objeto estelar (estrela ou galáxia) representado através de uma imagem de satélite. As arquiteturas de Rede Neural consideradas foram: (i) CNNs (pré-treinadas e treinadas from scratch); (ii) Redes Recorrentes (LSTM, GRU, e clássica); (iii) Multilayer Perceptrons sem recorrência e/ou convoluções.*

## 1. Introdução

A Cosmologia observacional possui como um de seus pilares a análise de observações astronômicas [de Dios Rojas Olvera et al. 2022]. Tais observações podem ser de diferentes tipos, como imagens de satélites, ondas de rádio, ondas eletromagnéticas, medições astronômicas, dentre outros. Entretanto, com o grande aumento no volume de dados disponíveis as técnicas clássicas de análise se tornam insuficientes [Fluke and Jacobs 2019]. Assim, abordagens de Aprendizado de Máquina estão sendo cada vez mais adotados na literatura [Fluke and Jacobs 2019]. Em particular, Redes Neurais Artificiais (ANNs) vem recebendo maior atenção e obtendo resultados promissores [de Dios Rojas Olvera et al. 2022].

O presente projeto implementou e expandiu o trabalho “*Performance Evaluation of Convolutional Neural Networks for Stellar Image Classification: A Comparative Study*” [Premanand et al. 2023], onde um estudo experimental com 3 arquiteturas de CNNs (do inglês, Convolutional Neural Networks) é realizado para a classificação de objetos astronômicos. Em particular, os autores desenvolveram um dataset formado por imagens de satélites de estrelas e galáxias, e CNNs foram utilizadas para classificação de tais imagens.

Dessa forma, nesse projeto foi utilizado o mesmo dataset<sup>1</sup> para o treinamento e avaliação de 10 classificadores baseados em Redes Neurais Artificiais com diferentes arquiteturas. Os resultados foram promissores, com alguns modelos obtendo performance superior ao melhor classificador em [Premanand et al. 2023].

---

<sup>1</sup><https://www.kaggle.com/datasets/divyansh22/dummy-astronomy-data/data>

## 2. Arquiteturas de Redes Neurais Artificiais

Essa seção contém os conceitos básicos das arquiteturas selecionadas. De acordo com [Du and Swamy 2019], a arquitetura de uma Rede Neural Artificial é representada através da matriz dos pesos de conexão entre neurônios  $\mathbf{W} = [w_{i,j}]$ , onde  $w_{i,j}$  representa o peso do neurônio  $i$  para o  $j$ . Ainda de acordo com os autores, podemos classificar as arquiteturas de ANNs em 2 grandes grupos: (i) Redes Feedforward; (ii) Redes Recorrentes.

### 2.1. Multilayer Perceptron (MLP)




Figura 1. Arquitetura geral de um MLP. [Du and Swamy 2019]

A arquitetura MLP é uma das mais comuns para redes *feedforward*. A Figura 1 contém uma esquematização geral dessa arquitetura. A característica geral dessa é a presença de uma ou mais *camadas escondidas* entre as entradas e saídas.

### 2.2. Recurrent Neural Network (RNN)




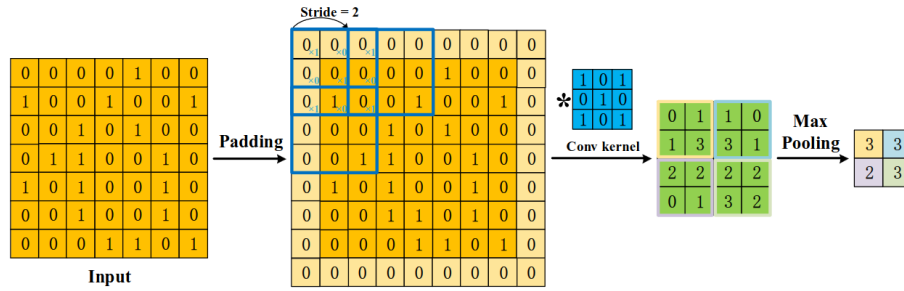
Figura 2. Célula recorrente clássica. [Yu et al. 2019]

Redes recorrentes possuem uma grande diferença das redes *feedforward*: a presença de uma conexão cíclica entre suas saídas e entradas. Essa característica

permite aprender relacionamentos em dados sequenciais (e.g., vídeo, áudio, textos) [Li et al. 2020]. A Figura 2 contém um exemplo de uma célula recorrente clássica.

Na literatura, são propostas diferentes células que implementam recorrência. As mais conhecidas são: (i) clássica (i.e., *sigma-cells*); (ii) Gated recurrent unit (GRU); e (iii) Long short-term memory (LSTM).

### 2.3. Convolutional Neural Network (CNN)



**Figura 3. Operação de convolução 2D. [Li et al. 2020]**

As redes convolucionais são uma escolha popular de redes *feedforward*, principalmente para aplicações de Visão Computacional e processamento de imagens. A Figura 3 demonstra o funcionamento básico da operação de convolução.

Na literatura, foram propostas diversas de arquiteturas de CNNs. Algumas consideradas clássicas para problemas de classificação [Li et al. 2020] são:

1. Redes VGG (2014)
2. ResNet (2015)
3. Inception v2 (2016)
4. Inception v4 (2017)
5. DenseNet (2017)
6. ResNetX (2017)
7. MobileNet v2 (2018)
8. MobileNet v3 (2019)


## 3. Metodologia e Materiais

Essa seção apresenta o dataset, arquiteturas implementadas e o método de avaliação selecionado. Cabe ressaltar que todas as escolhas se basearem no trabalho de [Premanand et al. 2023].


### 3.1. Dataset

O dataset considerado em [Premanand et al. 2023] possui um total de 3986 imagens classificadas em *Star e Galaxy*. Todas as imagens possuem resolução  $64 \times 64$  e são carregadas considerando o espaço RGB. A Figura 4 contém a distribuição das classes, onde é possível perceber que esse conjunto de dados é extremamente desbalanceado.

A Figura 5 contém exemplos de algumas instâncias do dataset. Uma característica geral das imagens é a presença de *ruído*. Técnicas de processamento de imagens podem



**Figura 4. Distribuição das classes no dataset completo.**



**Figura 5. Exemplos das imagens presentes no dataset.**

ser aplicadas para reduzir o ruído e mensurar o impacto na tarefa de classificação, todavia essa análise foge do escopo do presente projeto.

Para permitir uma comparação justa entre os diferentes classificadores, foram definidos splits de treinamento ( 70%, 2790 instâncias) e testes ( 30%, 1196 instâncias). A distribuição das classes é similar entre os splits, mais detalhes podem ser encontrados no código disponibilizado no GitHub.

### 3.2. ANNs para Classificação de Imagens

Para os experimentos, foram consideradas 11 variações de ANNs com diferentes arquiteturas. A Tabela 1 contém uma breve descrição para cada uma dessas variações. Mais detalhes de arquitetura se encontram disponíveis no código disponibilizado no GitHub.

Todas as redes foram treinadas utilizando *Backpropagation* ou *Backpropagation through time* (BPTT) no caso das RNNs. O mesmo algoritmo de otimização foi utilizado para todas elas: *AdamWA* com taxa de aprendizado 0.001. O *batch size* também foi o mesmo: 32 instâncias. No caso das redes pré-treinadas, o fine-tuning foi realizado na rede completa e com adição/modificação da cabeça de classificação.

Para utilizar as MLPs para classificação das imagens, foi-se utilizada uma es-

Rede	Descrição	Épocas
CNN <sub>1</sub>	CNN simples, 4 camadas, pesos aleatórios, Max pooling.	25
CNN <sub>2</sub>	CNN simples, 4 camadas, pesos aleatórios, Max pooling.	15
DenseNet-121	7.9 milhões de parâmetros, pré-treinado no ImageNet-1K.	10
ResNet-18	11.4 milhões de parâmetros, pré-treinado no ImageNet-1K.	10
VGG-16	138 milhões de parâmetros, pré-treinado no ImageNet-1K.	10
ConvNeXt <sub>base</sub>	659 milhões de parâmetros, pré-treinado no ImageNet-1K.	15
RNN	RNN clássica, 4 camadas, estado escondido com 64 dimensões.	25
GRU	GRU, 4 camadas, estado escondido com 64 dimensões.	25
LSTM	LSTM, 4 camadas, estado escondido com 64 dimensões.	25
MLP <sub>1</sub>	MLP simples, 3 camadas, pesos aleatórios.	25
MLP <sub>2</sub>	MLP simples, 3 camadas, pesos aleatórios.	25

**Tabela 1. Arquitetura das ANNs experimentadas.**

tratégia de *flatten*. Ou seja, dada uma imagem  $64 \times 64$  com 3 canais, a MLP recebe como entrada um vetor com  $64 \times 64 \times 3 = 12288$  dimensões.

Já para as RNNs, uma estratégia similar foi adotada, entretanto não é necessário realizar o *flatten* de todas as dimensões da imagem. Em especial, as RNNs recebem como entrada um sequência de  $64 \times 3 = 192$  vetores com tamanho 64 cada. Uma explicação intuitiva é que as RNNs recebem cada *linha* da imagem para cada um dos canais. Essa estratégia foi adotada de forma empírica e outras estratégias podem ser comparadas em trabalhos futuros.

### 3.3. Método de Avaliação

Para avaliar os diferentes classificadores, as métricas clássicas de classificação serão adotadas:  $F_1$ -score, precisão e recall. Em particular, as métricas serão calculadas para cada uma das classes bem como suas médias (macro, micro e ponderado). Nesse contexto, o objetivo dos classificadores é obter boas métricas para ambas as classes. Além disso, os valores para métrica acurácia são disponibilizados no código do GitHub.

## 4. Resultados e Discussão

A Tabela 2 contém as métricas de avaliação para cada classe e suas respectivas médias. As siglas  $M$  e  $W$  se referem às médias *macro* e *weighted* (ponderado) respectivamente.

Dos resultados, conseguimos perceber que as abordagens CNN<sub>1</sub> e CNN<sub>2</sub> obtiveram os melhores resultados. Em particular, a CNN<sub>2</sub> alcançou as melhores métricas em 8 das 12 métricas calculadas, podendo ser considerada a melhor rede dentre as experimentadas.

De qualquer forma, é possível notar que as redes, no geral, tiveram dificuldade em lidar com o desbalanceamento do dataset. Em alguns casos, algumas redes não foram capazes de reconhecer nenhuma das instâncias da classe *Galaxy* (e.g., VGG-16, LSTM).

	Precisão				Recall				$F_1$ -score			
	Star	Galaxy	$M$	$W$	Star	Galaxy	$M$	$W$	Star	Galaxy	$M$	$W$
<b>CNN<sub>1</sub></b>	0.897	<b>0.840</b>	<b>0.869</b>	0.883	0.959	0.662	<b>0.869</b>	0.886	0.927	0.740	0.834	0.881
<b>CNN<sub>2</sub></b>	<b>0.927</b>	0.777	0.852	<b>0.890</b>	0.928	<b>0.775</b>	0.851	<b>0.890</b>	<b>0.928</b>	<b>0.776</b>	<b>0.852</b>	<b>0.890</b>
<b>DenseNet-121</b>	0.917	0.754	0.836	0.877	0.921	0.744	0.833	0.878	0.919	0.749	0.834	0.878
<b>ResNet-18</b>	0.901	0.744	0.823	0.862	0.924	0.686	0.805	0.865	0.912	0.714	0.813	0.863
<b>VGG-16</b>	0.755	0.000	0.378	0.570	<b>1.000</b>	0.000	0.500	0.755	0.860	0.000	0.430	0.650
<b>ConvNeXt<sub>base</sub></b>	0.839	0.833	0.836	0.838	0.972	0.427	0.699	0.839	0.901	0.564	0.733	0.819
<b>RNN</b>	0.751	0.225	0.488	0.671	0.844	0.140	0.492	0.671	0.795	0.173	0.484	0.643
<b>GRU</b>	0.889	0.727	0.808	0.849	0.921	0.645	0.783	0.854	0.905	0.684	0.794	0.851
<b>LSTM</b>	0.755	0.000	0.378	0.570	<b>1.000</b>	0.000	0.500	0.755	0.860	0.000	0.430	0.650
<b>MLP<sub>1</sub></b>	0.780	0.444	0.612	0.697	0.918	0.201	0.560	0.742	0.843	0.277	0.560	0.705
<b>MLP<sub>2</sub></b>	0.797	0.404	0.601	0.701	0.835	0.345	0.590	0.715	0.816	0.372	0.594	0.707

**Tabela 2. Resultados das diferentes arquiteturas no conjunto de testes.  $M$  significa a média macro e  $W$  a ponderada.**

No geral, é possível perceber que as abordagens baseadas em CNN alcançaram resultados mais promissores. Isso é esperado, visto que tais arquiteturas costumam obter os melhores resultados para problemas relacionados com o processamento de imagens.

Ademais, os resultados indicam que considerar apenas a acurácia média como feito em [Premanand et al. 2023] não é uma opção viável, já que tal valor não reflete o desempenho do classificador na classe minoritária. O melhor modelo obtido neste projeto (i.e., CNN<sub>2</sub>) obteve uma acurácia macro de 85.138% e ponderada de 89.047%, superando os melhores resultados reportados no artigo supracitado.

Todavia, é importante ressaltar que o projeto atual ainda possui limitações. Uma delas é o uso de estratégias de processamento de imagens para lidar com os ruídos inerentes das observações. Outro seria considerar técnicas para lidar com o desbalanceamento do dataset (e.g., peso na função de perda, nova função de perda), buscando mitigar a dificuldade observada no treinamento dos modelos. Além disso, também fazem-se necessários novos experimentos para compreender o impacto do pesos pré-inicializados no ImageNet-1K, já que tal dataset não possui classes relacionadas com observações astronômicas.

## Referências

- de Dios Rojas Olvera, J., Gómez-Vargas, I., and Vázquez, J. A. (2022). Observational cosmology with artificial neural networks. *Universe*, 8(2):120.
- Du, K.-L. and Swamy, M. N. S. (2019). *Neural Networks and Statistical Learning*. Springer London.
- Fluke, C. J. and Jacobs, C. (2019). Surveying the reach and maturity of machine learning and artificial intelligence in astronomy. *WIREs Data Mining and Knowledge Discovery*, 10(2).
- Li, Z., Yang, W., Peng, S., and Liu, F. (2020). A survey of convolutional neural networks: Analysis, applications, and prospects.
- Premanand, N., VG, T., Pawar, S., DN, J., Utsav, S. D., J. J., and M, V. (2023). Performance evaluation of convolutional neural networks for stellar image classification: A comparative study. In *2023 International Conference on Data Science and Network Security (ICDSNS)*. IEEE.
- Yu, Y., Si, X., Hu, C., and Zhang, J. (2019). A review of recurrent neural networks: Lstm cells and network architectures. *Neural Computation*, 31(7):1235–1270.